EXP4 算法基础实验报告

廖佳怡 PB19151776

1. 实验设备和环境

编译环境：Windows10

编程语言：C++

机器内存：16.0GB

时钟主频：2.30GHz

2. 实验内容及要求

- 实验3.1 KMP算法
  - 内容

    给定文本串T、模式串P，T的长度为n，P的长度为m，采用KMP算法进行字符串匹配。
  - 要求
    - (n, m)共有5组取值，分别为: (28，23), (29，24), (210,25), (211,26), (212,27)，见/ex1/input/4_1_input.txt。
    - 输出所有匹配的T的开始下标和Π的函数值，记录找到所有匹配的时间，并画出曲线分析。
    - 关于画图分析，KMP算法计算前缀函数的复杂度是O(m)，实际匹配的复杂度是O(n)，画图时这两块可以分开画，横坐标分别取m和n。或者，考虑到算法总复杂度是O(m+n)，n比m大得多，不妨以n为横坐标，直接画总运行时间的曲线。
- 实验3.2 RK算法
  - 内容

    给定文本串T、模式串P，T的长度为n，P的长度为m，采用Rabin-Karp算法进行字符串匹配。
  - 要求
    - (n, m)共有5组取值，分别为: (28，23), (29，24), (210,25), (211,26), (212,27)，见/ex2/input/4_2_input.txt。
    - 基数d和素数q共4组取值，(d,q)分别为：(2,13),(2,1009),(10,13),(10,1009)
    - 输出所有匹配的T的开始下标和伪命中次数，记录找到所有匹配的时间，并画出曲线分析。其中，伪命中指Hash值相等但并不匹配的情况。
    - 关于画图分析，RK算法最坏复杂度是O(mn)，考虑到n比m大得多，这里可以直接以n作横坐标，或以mn为横坐标，然后不同(d,q)不同曲线。

3. 方法和步骤

Exp1

- 方法

  KMP算法由有限自动机发展而来，无需计算转移函数，只用根据模式预先计算$\pi[q]=max\{k:k<q且P_k \sqsupset P_q\}$。具体地，通过`Compute_Prefix`将模式自身与自身匹配，计算$\pi$数组，然后通过`KMP_Matcher`函数利用$\pi$数组将模式与待匹配字符串进行匹配。

- 步骤（关键代码展示）

  - Compute_Prefix:

```
void Compute_Prefix(const string& P)
{
    int m=P.length();
    pi[0]=-1;
    int k=-1;
    for(int q=1;q<m;q++)
    {
        while(k>-1 && P[k+1]!=P[q])
            k=pi[k];
        if(P[k+1]==P[q])
            k++;
        pi[q]=k;
    }
}
```

  - KMP_Matcher

```
int KMP_Matcher(const string& P,const string& T)
{
    int n=T.length();
    int m=P.length();
    Compute_Prefix(P);
    int q=-1,cnt=0;
    for(int i=0;i<n;i++)
    {
        while(q>-1 && P[q+1]!=T[i])
            q=pi[q];
        if(P[q+1]==T[i])
            q++;
        if(q==m-1)
        {
            cnt++;
            s[cnt]=i-m+1;
            q=pi[q];
        }
    }
    return cnt;
}
```

Exp2

- 方法

  RK算法基本思想是：计算出模式P在d进制下的数字，与文本的每个可能字串计算出的d进制下的数字进行比较，若相等则粗略判断其可能命中，再通过逐一比较精确确定是否命中（即排除伪命中）。由于计算的数字可能很大，故采用模q运算。

- 步骤（关键代码解析）

```
void RK_Matcher(const string& P,const string& T,int d,int q)
{
    int n=T.length(),m=P.length();
    int h=d%q;
    if(h<0)h+=q;
    for(int i=1;i<=m-2;i++)
    {
        h=(h*d)%q;
        if(h<0)h+=q;
    }
    int p=0,t=0;
    cnt=0,false_cnt=0;
    for(int i=0;i<m;i++)
    {
        p=(d*p+P[i])%q;
        if(p<0)p+=q;
        t=(d*t+T[i])%q;
        if(t<0)t+=q;
    }
    for(int s=0;s<=n-m;s++)
    {
        if(p==t)
        {
            false_cnt++;
            bool matched=true;
            for(int i=0;i<m;i++)
            {
                if(P[i]!=T[s+i])
                {
                    matched=false;
                    break;
                }
            }
            if(matched)
            {
                cnt++;
                shift[cnt]=s+1;
            }
        }
        if(s<n-m)
        {
            t=(d*(t-T[s]*h)+T[s+m])%q;
            if(t<0)t+=q;
        }
    }
}
```

  - 计算P和T在d进制下的模q数p、t：

```
int p=0,t=0;
cnt=0,false_cnt=0;
for(int i=0;i<m;i++)
{
    p=(d*p+P[i])%q;
    if(p<0)p+=q;
    t=(d*t+T[i])%q;
    if(t<0)t+=q;
}
```

- 粗略判断与精细判断命中：

```
    for(int s=0;s<=n-m;s++)
    {
        if(p==t)
        {
            false_cnt++;
            bool matched=true;
            for(int i=0;i<m;i++)
            {
                if(P[i]!=T[s+i])
                {
                    matched=false;
                    break;
                }
            }
            if(matched)
            {
                cnt++;
                shift[cnt]=s+1;
            }
        }
        if(s<n-m)
        {
            t=(d*(t-T[s]*h)+T[s+m])%q;
            if(t<0)t+=q;
        }
    }
```

4. 结果和分析

Exp1

- 结果

  完整版结果见result.txt

```
2
0 0 0 1 2 1 1 2
71 188

2
0 1 0 0 1 0 0 0 1 2 3 1 0 1 2 3
233 294

2
0 1 0 0 1 0 0 1 2 3 4 5 2 3 1 0 1 2 2 3 4 0 1 0 1 2 3 1 2 3 4 5
440 697

2
0 0 0 1 1 2 3 4 5 1 1 2 1 2 1 2 3 0 0 1 1 2 3 0 1 2 3 4 2 3 4 5 6 7 8 9 10 2 3 0 1 2 1 1 1 1 1 2 3 0 0 1 2 1 1 1 2
927 1907

2
0 1 2 3 0 0 1 2 0 1 2 0 1 0 1 2 3 4 4 4 5 1 2 0 1 0 0 1 2 3 0 0 0 1 2 3 4 4 5 6 7 8 9 0 1 0 1 2 3 4 4 4 5 6 7 0 0
1123 2726
```

- 时间
  - 理论时间复杂度分析：

    由于在`Compute_Prefix`中每次操作都与k的值变化相关（每次k的值变化，操作时间为O(1)）。而k有两种变化，递增1和递减为$\pi[k]$。由于k的值不超过m，由聚合分析，k的变化次数为O(m)的，故运行时间为O(m)。

    在`KMP_Matcher`中可由类似聚合分析得知运行时间为O(n)的。

    故总时间为O(m+n)。
  - 实际运行时间：

    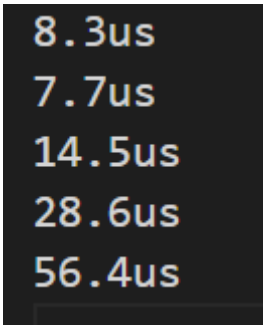

    将运行时间t与(m+n)拟合如下图，$R^2 = 0.9936$，与理论时间复杂度符合。

    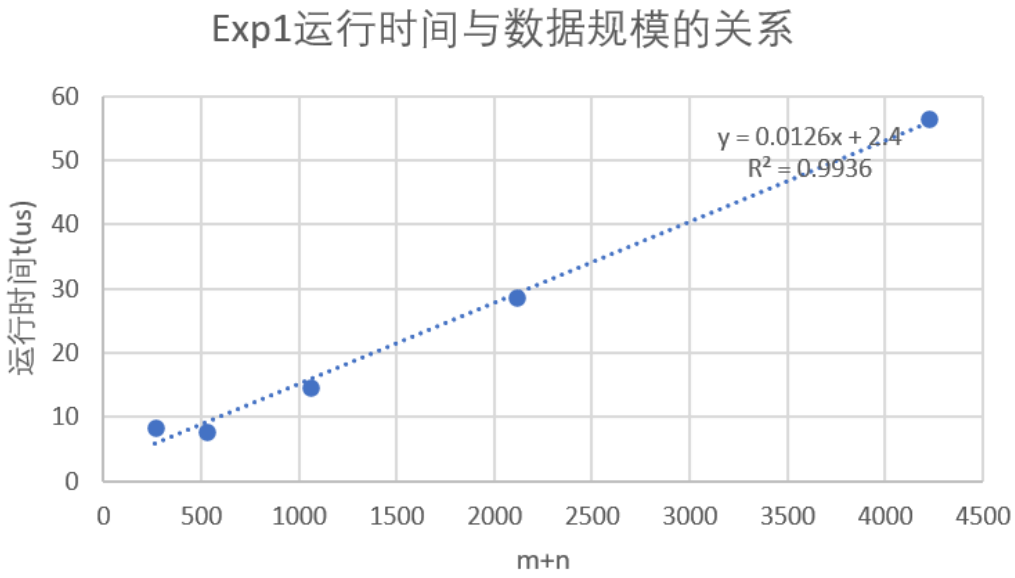

Exp2

- 结果

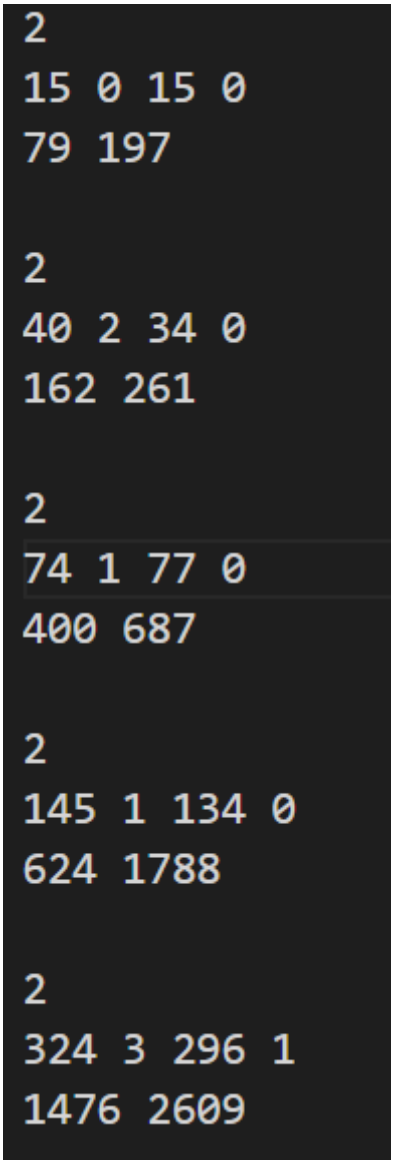

- 时间
  - 理论时间复杂度分析：

    RK算法的预处理时间(第一个循环有m次)为O(m)，平均匹配时间（第二个循环外循环有n-m次，精确匹配为m次循环）为O(n)的。
  - 实际运行时间：

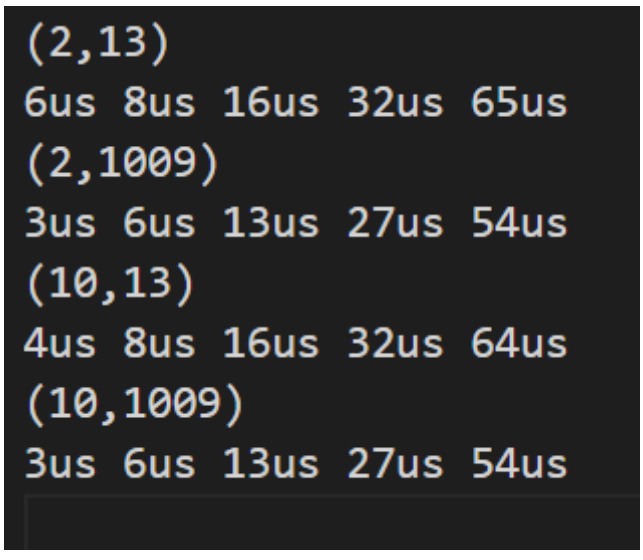

将运行时间t与mn拟合如下图（图中有两条线重合了），R^2分别为0.9987,0.9999,1,0.9999，与理论时间复杂度符合。